

হ্যাঁ। তোমার **PMS5003** থাকলে এই project-টা আগের চেয়ে অনেক বেশি practical, কারণ PMS5003 থেকে **PM1.0, PM2.5** এবং **PM10** পাওয়া যায়। আর একটা গুরুত্বপূর্ণ correction: 2021 IEEE paper-টা আসলে **PM2.5 + PM10 + temperature + humidity → PEFr → asthma-risk** approach নিয়েছিল; MQ135 তাদের model-এর input ছিল না। তারা PEFr-কে patient-specific best PEFr-এর সঙ্গে compare করে Green/Yellow/Red label বানিয়েছে। ([ResearchGate](#))

আমি নিচে তোমাদের **hardware** দিয়ে কীভাবে পুরো **project**টা করবে, সেটা একদম শুরু থেকে ML deployment পর্যন্ত সাজিয়ে দিচ্ছি।

1. প্রথমে **Project**-এর **actual goal** ঠিক করি

তোমাদের system-এর goal হবে:

Real-time indoor environmental conditions ব্যবহার করে **asthma exacerbation risk estimate** করা।

তোমার hardware:

DHT22

- Temperature
- Humidity

PMS5003

- PM1.0
- PM2.5
- PM10

MQ135

- Gas sensor reading

ESP32

কিন্তু প্রথম **ML version**-এ **MQ135** ব্যবহার না করাই ভালো।

কারণ original asthma study/model-এ MQ135 নেই। Model input ছিল:

Temperature

Humidity

PM2.5

PM10

তারপর output:

Green → Safe

Yellow → Moderate Risk

Red → High Risk

Paper-টিও একইভাবে PM2.5, PM10, outdoor temperature এবং humidity-কে input হিসেবে উল্লেখ করেছে। ([ResearchGate](#))

MQ135 পরে **optional/experimental feature** হিসেবে যোগ করতে পারো।

2. সবচেয়ে বড় সমস্যা: তোমার **ML training dataset**

এখানে একটা জিনিস খুব পরিষ্কারভাবে বুঝতে হবে।

তুমি শুধু:

Temperature

Humidity

PM2.5

PM10

এর dataset পেলেই asthma ML train করতে পারবে না।

কারণ model-কে শেখাতে হবে:

এই environmental condition → asthma risk কত?

তাই training data-তে **health outcome/label** লাগবে।

Original 2021 paper-এ সেটা ছিল:

PEFR (Peak Expiratory Flow Rate)।

14 জন pediatric asthma patient-এর PEFR data নেওয়া হয়েছিল। PEFR দিনে দুইবার record করে 10-minute interval-এ interpolate করা হয়েছিল। তারপর প্রত্যেক patient's best PEFR-এর percentage অনুযায়ী label করা হয়েছিল। ([ResearchGate](#))

3. Label কীভাবে তৈরি হয়েছিল?

ধরো একজন patient's best PEFr:

500 L/min

তারপর কোনো সময়:

450 L/min

তাহলে:

$$450 / 500 \times 100 \\ = 90\%$$

→ **Green / Safe**

আর যদি:

$$350 / 500 \times 100 \\ = 70\%$$

→ **Yellow / Moderate**

আর:

$$200 / 500 \times 100 \\ = 40\%$$

→ **Red / High Risk**

Paper-এর thresholds:

PEFR vs patient's best	Label
>80%	 Green / Safe
50–80%	 Yellow / Moderate Risk
<50%	 Red / High Risk

([ResearchGate](#))

এই label-টাই **ML target**।

4. তাহলে তোমার **ML dataset** দেখতে কেমন হবে?

Ideal training dataset:

timestamp
temperature
humidity
pm1_0
pm2_5
pm10
risk_label

যেমন:

Temp	Humidity	PM2.5	PM10	Label
27.1	55	8	14	Green
28.4	61	15	27	Green
30.2	70	35	62	Yellow
31.5	78	58	105	Red

কিন্তু এগুলো **illustrative values**। এগুলো দিয়ে model train করবে না।

তোমার actual labeled dataset লাগবে।

5. এখানে **AAMOS-00 dataset** একটা **interesting alternative**

আগের dataset নিয়ে আমরা কথা বলেছিলাম।

University of Edinburgh-এর **AAMOS-00** dataset publicly downloadable। এতে:

- environment data
- peak flow data
- daily questionnaire

- smart inhaler
- smartwatch
- patient information

আলাদা CSV আছে। ([Edinburgh DataShare](#))

আর researchers নিজেরাই starter code দিয়েছে যেখানে dataset join করে **binary classification** করার example আছে। ([GitHub](#))

এটা তোমার জন্য useful হতে পারে।

তবে একটা caveat:

AAMOS-00-এর environment data তোমার **PMS5003/DHT22-এর exact sensor data** নয়।

তাই আমরা প্রথমে dataset inspect করব।

6. Dataset → তোমার model-এর input তৈরি

ধরো AAMOS/environment dataset থেকে আমরা পাই:

timestamp
temperature
humidity
PM2.5
PM10
...

এবং peak-flow/questionnaire থেকে পাই asthma outcome।

তখন আমরা merge করব:

```

Environment Data
+
Peak Flow / Health Data
↓
Timestamp matching
↓
Final ML Dataset

```

Final:

X = [

```
temperature,  
humidity,  
PM2.5,  
PM10  
]  
  
y = [  
    asthma risk  
]
```

7. কিন্তু এখানে একটা খুব গুরুত্বপূর্ণ **ML decision** আছে

তুমি দুইভাবে model বানাতে পারো।

Approach A — Classification

Directly:

```
Temperature  
Humidity  
PM2.5  
PM10  
↓  
Classifier  
↓  
Green / Yellow / Red
```

Models:

- Random Forest
- XGBoost
- SVM
- Logistic Regression
- Decision Tree

এটা তোমাদের project-এর জন্য সবচেয়ে সহজ এবং **explainable**।

8. Approach B — Regression → Classification

এটাই actually **original IEEE paper**-এর কাছাকাছি।

তারা environmental inputs দিয়ে **PEFR estimate** করেছে। তারপর estimated PEFR থেকে risk category তৈরি করেছে। Paper-এ CNN দিয়ে regression-based PEFR prediction করা হয়েছিল এবং পরে:

PEFR > 80% → Safe

50–80% → Moderate

<50% → High

করেছে। ([ResearchGate](#))

তোমাদের project-এ:

Temperature

Humidity

PM2.5

PM10

↓

ML Regression

↓

Predicted PEFR

↓

% of Best PEFR

↓

Risk category

এটা academically বেশি interesting।

9. কিন্তু তোমাদের জন্য আমি কোনটা **recommend** করব?

প্রথম **version**:

Classification

কারণ:

Input



Random Forest



Green / Yellow / Red

বোঝানো সহজ।

তারপর paper-এর methodology reproduce করতে চাইলে:

Advanced version:

Regression + classification

Environmental data



CNN / XGBoost Regressor



Predicted PEFR



Risk classification

10. Model training শুরু করার আগে EDA

Dataset পাওয়ার পর প্রথম কাজ model train করা না।

প্রথমে:

Step 1 — Missing values

```
df.isnull().sum()
```

দেখবে।

Step 2 — Data types

```
df.info()
```

Step 3 — Statistics

```
df.describe()
```

Step 4 — Target distribution

```
df["risk_label"].value_counts()
```

এটা খুব important।

ধরো:

Green	8000
Yellow	700
Red	100

তাহলে model Green predict করেই high accuracy পেয়ে যাবে।

তাই class imbalance handle করতে হবে।

11. Feature engineering

Raw values-এর পাশাপাশি কিছু useful features বানাতে পারো।

PM ratio

PM2.5 / PM10

Temperature-Humidity interaction

Temperature × Humidity

Rolling PM2.5

যদি timestamp থাকে:

5-minute average PM2.5

15-minute average PM2.5

30-minute average PM2.5

এগুলো asthma-related environmental exposure বোঝাতে useful হতে পারে।

কিন্তু **training dataset**-এ **temporal structure** থাকলে তবেই এগুলো করবে।

12. Train-test split

এখানে random split blindly করা যাবে না।

কারণ time-series data।

ধরো:

January → Training

February → Validation

March → Testing

এটা better।

অথবা patient-wise split:

Patient 1–10 → Training

Patient 11–12 → Validation

Patient 13–14 → Test

Asthma dataset-এ patient leakage এড়ানো খুব গুরুত্বপূর্ণ।

একই patient's data training এবং test দুটোতে ঢুকলে model patient-specific pattern মুখস্থ করে ফেলতে পারে।

13. Model 1 — Logistic Regression

Baseline হিসেবে:

`LogisticRegression()`

দেবে।

এতে বোঝা যাবে simple linear relationship কতটা কাজ করে।

14. Model 2 — Random Forest

আমি এটা strongly recommend করব।

```
RandomForestClassifier(  
    n_estimators=200,  
    class_weight="balanced",  
    random_state=42
```

)

কারণ:

- nonlinear relationship ধরতে পারে
 - small/medium tabular dataset-এ ভালো
 - feature importance পাওয়া যায়
 - explain করা সহজ
 - ESP32-তে final deployment-এর জন্য model lightweight করা সম্ভব
-

15. Model 3 — XGBoost

তারপর:

Random Forest

vs

XGBoost

compare করবে।

Metrics:

- Accuracy
- Precision
- Recall
- F1-score
- Confusion Matrix

Asthma risk-এর ক্ষেত্রে **Recall** গুরুত্বপূর্ণ।

কারণ:

আসল High Risk patient-কে যদি model Safe বলে দেয়, সেটা dangerous false negative।

তাই শুধু accuracy দেখানো যাবে না।

16. Example evaluation

ধরো test result:

Accuracy = 87%
F1 = 0.84
High-risk recall = 91%

তাহলে বলতে পারো:

The model successfully identified high-risk environmental-health conditions with 91% recall.

কিন্তু actual values অবশ্যই তোমাদের trained model থেকে আসতে হবে।

17. SHAP যোগ করলে **project** অনেক **stronger** হবে

তোমার আগের research interest-এর সঙ্গে এটাও nicely যায়।

Model prediction:

Prediction:
YELLOW — Moderate Risk

SHAP explain করবে:

PM2.5 → pushes risk higher
PM10 → pushes risk higher
Humidity → slightly higher
Temperature → neutral

Dashboard:

ASTHMA RISK

● MODERATE


Why?


PM2.5		High contribution
PM10		Moderate contribution
Humidity		Low contribution
Temperature		Low contribution

এতে projectটা শুধু ML classification না হয়ে **Explainable ML-based monitoring system** হবে।

18. এবার তোমার PMS5003 + DHT22 দিয়ে real-time অংশ

এখানে খুব simple architecture হবে:





19. ESP32 কী করবে?

ESP32-এর কাজ **ML** করা না।

ESP32 শুধু sensor data collect করবে।

প্রতি 1 minute:

Temperature = 28.4

Humidity = 65.2

PM2.5 = 17.8

PM10 = 29.3

তারপর JSON:

```
{  
  "temperature": 28.4,  
  "humidity": 65.2,  
  "pm25": 17.8,  
  "pm10": 29.3  
}
```

server-এ পাঠাবে।

20. Backend কী করবে?

FastAPI:

POST /predict

ESP32 data পাঠাবে।

Backend:

```
X = [[  
  temperature,
```

```
humidity,  
pm25,  
pm10  
]]
```

তারপর:

```
prediction = model.predict(X)
```

Result:

```
{  
  "risk": "Moderate"  
}
```

21. MQ135 কোথায় রাখবে?

আমি বলব **Version 1**-এ **model input** করো না।

কারণ original asthma dataset/model-এর সঙ্গে MQ135-এর corresponding feature নেই।

কিন্তু dashboard-এ রাখতে পারো:

Environmental Monitoring

Temperature	28.4 °C
Humidity	65 %
PM2.5	17.8 µg/m³
PM10	29.3 µg/m³
MQ135	412 ADC

ML Asthma Risk

● MODERATE

এতে sensorটা project-এর অংশ থাকবে কিন্তু **unsupported feature** দিয়ে **model corrupt** হবে না।

Version 2

নিজেদের sufficient real-world labeled data collect করতে পারলে:

Temperature
Humidity
PM2.5
PM10
MQ135

সব দিয়ে নতুন model train করতে পারো।

তখন experimentally দেখাতে পারবে:

Does MQ135 improve asthma-risk prediction?

এটা কিন্তু একটা সুন্দর research question।

22. "Real-time cross validation" কথাটা একটু ঠিক করি

তুমি বলেছিলে:

real-time data নিয়ে ML দিয়ে cross validate/decision prediction

এখানে **cross-validation real-time prediction**-এর সময় করা হয় না।

দুইটা আলাদা জিনিস:

Cross-validation

Training phase:

Dataset

↓

5-Fold Cross Validation

↓

Model selection

Real-time prediction

Deployment phase:

ESP32

↓

New unseen sensor data



Trained model



Prediction

অর্থাৎ:

OFFLINE

Dataset



Preprocessing



Train/Validation



5-fold CV



Final Model



Save model.pkl

ONLINE

PMS5003 + DHT22



ESP32



API



model.pkl



Risk Prediction

এটাই proper ML workflow।

23. Cross-validation কীভাবে করবে?

ধরো Random Forest:

Dataset



5 Fold

তারপর:

Fold 1 → test

Fold 2–5 → train

Fold 2 → test

Fold 1,3,4,5 → train

...

Fold 5 → test

তারপর average:

CV Accuracy

CV Precision

CV Recall

CV F1

তিনটা model compare:

Model	CV F1	High-risk Recall
Logistic Regression	...	...
Random Forest	...	...
XGBoost	...	...

তারপর best model deployment করবে।

24. তোমাদের final project-এর research pipeline

আমি হলে পুরো projectটা এভাবে করতাম:

Phase 1 — Dataset

AAMOS-00 / suitable asthma dataset সংগ্রহ।

AAMOS-00-এর official DataShare repository-তে environment এবং peak-flow CSV সহ পুরো dataset publicly available। ([Edinburgh DataShare](#))

Phase 2 — Data processing

Environment CSV

+

Peakflow CSV

+

Patient information

↓

Timestamp alignment

↓

Clean dataset

Phase 3 — Label

PEFR-based:

>80% → Safe

50–80% → Moderate

<50% → High

অথবা **AAMOS-00**-এর **actual asthma outcome label** ব্যবহার করা, dataset-এর data dictionary দেখে।

Phase 4 — Feature selection

Initial:

Temperature

Humidity

PM2.5

PM10

Phase 5 — ML

Logistic Regression

Random Forest

XGBoost

Phase 6 — Validation

Patient-wise / time-aware split

+

5-fold CV where appropriate

- + Confusion Matrix
- + F1
- + High-risk Recall

Phase 7 — Explainability

SHAP

Phase 8 — Hardware

DHT22
PMS5003
ESP32

Phase 9 — Deployment

ESP32
↓
Wi-Fi
↓
FastAPI
↓
ML model
↓
Prediction

Phase 10 — Dashboard

Streamlit:

ASTHMA ENVIRONMENT MONITOR		
Temperature	28.4 °C	
Humidity	65.2 %	
PM2.5	17.8 µg/m³	
PM10	29.3 µg/m³	
MODERATE RISK		
Main contributing factors		

PM2.5	██████████	██████████	██████████	██████████	██████████
PM10	██████████	██████████	██████████	██████████	██████████
Humidity	██████████	██████████	██████████	██████████	██████████
Temperature	██████████	██████████	██████████	██████████	██████████

⚠️ কিন্তু একটা খুব গুরুত্বপূর্ণ **limitation**

এই system-কে **medical diagnostic device** হিসেবে claim করবে না।

তোমাদের model আসলে:

environmental conditions থেকে **asthma-risk/exacerbation risk estimate**


করবে।


এটা "তোমার asthma attack হবে"—এমন diagnosis নয়।

Original paper-ও PEFr-based risk prediction approach নিয়েছে; তাদের goal ছিল assistive risk prediction tool। ([ResearchGate](#))

আমার মতে তোমাদের সবচেয়ে ভালো **final architecture**

PMS5003 + DHT22-কে core ML sensors বানাও।





MQ135-কে এখন **auxiliary monitoring sensor** রাখো। পরে যদি enough labeled data collect করতে পারো, **MQ135** add করে **Model A (without MQ135) vs Model B (with MQ135)** compare করা যাবে। সেটা project-এর একটা সুন্দর experimental contribution হতে পারে।

আর সবচেয়ে গুরুত্বপূর্ণ next step হলো **AAMOS-00**-এর **actual CSV**গুলো খুলে দেখা—বিশেষ করে **environment.csv**, **peakflow.csv**, আর **data_dictionary.xlsx**। Official repository-তেই এগুলো downloadable আছে। ([Edinburgh DataShare](#))

সেখান থেকে আমরা **exactly** কোন **column** দিয়ে **X**, কোন **column** দিয়ে **y**, কীভাবে দুই **CSV merge** করতে হবে, কোন **rows** বাদ দিতে হবে, এবং তোমাদের **PMS5003**-এর **PM2.5/PM10**-এর সাথে **dataset**-এর কোন **column map** করবে—সেটা নির্ধারণ করতে পারব।